


Aplicación de una red neuronal y backpropagation para el diagnóstico de fallas mecánicas en motores de encendido

Application of a neural network
and backpropagation for the
diagnosis of mechanical failures in
ignition engines

Autor: **Jhonatan Mateo Angulo Henao**
IS&C, Universidad Tecnológica de Pereira, Pereira, Colombia
Correo-e: **Jhonatan.angulo@utp.edu.co**

Resumen—

En la presente investigación se explica la metodología para la creación de un sistema de diagnóstico aplicado a la detección de fallas mecánicas en vehículos con motores a gasolina mediante redes neuronales artificiales, el sistema se basa en el estudio de la fase de admisión del ciclo Otto, el cual es registrado a través de la implementación física de un sensor MAP (*Manifold Absolute Pressure*).



Palabras clave— perceptrón, redes neuronales, backpropagation, software, computación, investigación, IA.

Abstract— In this research, the methodology for the creation of a diagnostic system applied to the detection of mechanical failures in vehicles with gasoline engines through artificial neural networks is explained, the system is based on the study of the intake phase of the Otto cycle, which is registered through the physical implementation of a MAP (*Manifold Absolute Pressure*) sensor.

1 INTRODUCCIÓN

Red de elementos o unidades de procesamiento simples EP/UP en español o PE/PU en inglés), interconectados entre sí mediante conexiones sinápticas en las que cada conexión tiene un peso (fuerza) que se ajusta a partir de la experiencia (datos).

En la actualidad en el área del transporte automotor los operarios y técnicos utilizan diagramas rudimentarios para el diagnóstico y reparación de motores de encendido provocado (MEP), lo que implica, subjetividad en el diagnóstico, desventajas en el tiempo de detección de fallas, falta de asertividad, y como consecuencia, se tienen altos costos de mantenimiento.

Por todo lo antes expuesto, es necesario aplicar nuevas metodologías y técnicas especializadas para conseguir diagnósticos en tiempos cortos que optimicen recursos para la detección de fallos en motores de vehículos a gasolina [1].

La complejidad de análisis e interpretación de parámetros de operación que intervienen en el MEP hace necesario el uso de redes neuronales y matemática computacional para un eficiente diagnóstico de fallos mecánicos en motores de ciclo Otto. La investigación de Howlett [2] muestra que mediante el análisis de la señal de la bujía con redes neuronales artificiales se puede monitorear el MEP para un diagnóstico o control de fallas.

1.2 Métodos y materiales

En la presente sección se desarrollan las temáticas principales que tienen que ver con la selección de unidad experimental e instrumentación mínimamente invasiva, condiciones de toma de muestras, metodología para la adquisición de datos, obtención de matriz de atributos, reducción de atributos, selección de atributos para entrenamiento de la RNA y algoritmo de la red neuronal en Matlab.

Selección de la unidad experimental e instrumentación mínimamente invasiva

Se toma en consideración como principal objetivo evitar el desarmado de elementos y piezas del motor para diagnosticar fallas mecánicas, por lo que se determina medir la depresión del motor mediante la instalación de un sensor tipo MAP en una toma de vacío del múltiple de admisión,

ubicándolo después de la mariposa de aceleración, de tal manera que la conexión no afecta el funcionamiento del motor.

La identificación de cada uno de los cilindros se realiza mediante el registro de la señal del sensor CMP. En la Figura 1 se presentan la unidad experimental puesta a prueba Motor Hyundai Sonata 2.0 DOHC, una computadora personal (PC), tableta, Ni DAQ-

6009 y la interfaz del escáner automotor. En la Figura 2 se muestra la conexión del sensor MAP, la toma de vacío en el múltiple de admisión y la herramienta de adquisición de datos Ni DAQ-6009.



Figura 1. Instrumentación en el motor.



Figura 2. Conexión del sensor MAP.

Condiciones de toma de muestras

Se utiliza el *software* Labview 2017 junto con una tarjeta Ni DAQ-6009, para la obtención de muestras. Las muestras se adquieren en ralentí aproximadamente a 850 rpm con un rango de temperatura del MEP de entre 92 °C y 97 °C, carga del motor de 40 % y se aplica el escáner automotor para corroborarlas. Según un estudio preexperimental se determina que la señal del sensor MAP posee picos de mayor frecuencia, de tal manera que se realiza la toma de muestras a una velocidad de 10 KHz en un tiempo de 5 segundos para cada una de las señales, dicha

velocidad supera el criterio de Nyquist (1.416 KHz).

1.3 Metodología para la obtención de datos

En la Figura 3 se presentan los elementos físicos necesarios para el muestreo de señales.




Figura 4. Elementos necesarios para la toma de muestras.

Para obtener los datos de las señales de los sensores MAP y CMP se sigue el flujograma de proceso que se presenta en la Figura 4.

1.4 Condiciones de toma de muestras

Se utiliza el *software* Labview 2017 junto con una tarjeta Ni DAQ-6009, para la obtención de muestras. Las muestras se adquieren en ralentí aproximadamente a 850 rpm con un rango de temperatura del MEP de entre 92 °C y 97 °C, carga del motor de 40 % y se aplica el escáner automotor para corroborarlas. Según un estudio preexperimental se determina que la señal del sensor MAP posee picos de mayor frecuencia, de tal manera que se realiza la toma de muestras a una velocidad de 10 KHz en un tiempo de 5 segundos para cada una de las señales, dicha velocidad supera el criterio de Nyquist (1.416 KHz).

1.5 Metodología para la obtención de datos

En la Figura 3 se presentan los elementos físicos necesarios para el muestreo de señales.




Figura 3. Elementos necesarios para la toma de muestras.

Para obtener los datos de las señales de los sensores MAP y CMP se sigue el flujograma de proceso que se presenta en la Figura 4.

El proceso de obtención de datos se inicia con la revisión del motor en correcto funcionamiento o falla supervisada, posterior a ello se procede a inspeccionar la conexión de los sensores. Si la conexión es correcta, se graba la señal con el *software* Labview y se registra en un archivo de Excel, de lo contrario, se procede a verificar la conexión de los sensores. Para registrar las señales se aplica el procedimiento antes descrito tanto para el caso de motor en buen funcionamiento como para el motor con falla supervisada, Figura 4(a); 4(b).

En la Tabla 1 se indica el total de 18 fallas que se generan en la unidad experimental, cada una con su respectivo código de identificación; también se indica la condición del motor en óptimo funcionamiento.

Obtención de matriz de atributos

Una vez desarrollada la adquisición de señales temporales se procedió a elaborar un algoritmo en el *software* Matlab para lectura y obtención de matriz general de atributos. Dichos atributos son los siguientes: media geométrica, máximo, mínimo, mediana, covarianza, varianza, desviación estándar, moda, factor de curtosis, coeficiente de asimetría, energía, potencia, área bajo la curva, entropía, coeficiente de variación, rango, raíz media cuadrática y factor de cresta.

En la Figura 5 se ilustra el corte completo de un ciclo Algoritmo de la red neuronal en Matlab

Mediante el uso de la plataforma de RNA del *software* Matlab se realizaron diferentes configuraciones para obtener una generalización de la red con un mínimo error.

En la Figura 7 se presenta el flujograma de la creación de la RNA.

El algoritmo inicia con la lectura de la matriz de entrada y respuesta respectiva para la RNA. Luego se normaliza el vector de entrada y la respuesta con el valor máximo de cada matriz con el objetivo de optimizar la creación de la

1.6 Resultados y discusión

A fin de comparar el correcto funcionamiento del sistema de diagnóstico se procede a realizar varias pruebas bajo diversas condiciones de funcionamiento.

En este apartado se presentan dos condiciones de falla en específico: el inyector 1 (200) y el fallo en bobina 2-3 (1100).

RNA. Una vez normalizada la matriz de atributos

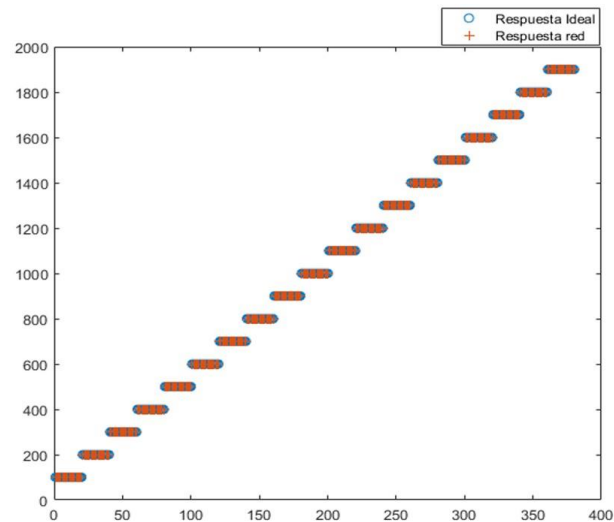


Figura 5. Red neuronal con porcentaje de error de $1.89\text{e-}11$, con función de entrenamiento «trainscg».

se procedió a la creación de la RNA.

del motor ($720^\circ \pm 180^\circ$), con el reglaje de distribución de adelanto a la apertura de admisión (AAA) y retraso de cierre de admisión (RCA), correspondiente a cada uno de los cilindros, del cual se realiza un ventaneo que se observa en la Figura 6 y se obtiene la caracterización de la señal.

Reducción de atributos

Para la selección y reducción del número de atributos se analiza la matriz general a través de 3 métodos estadísticos: ANOVA, matriz de correlación y Random Forest.

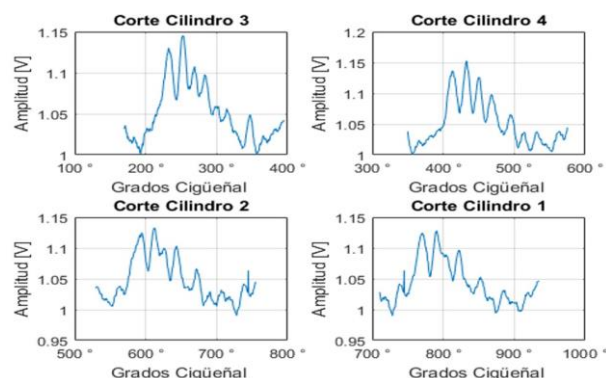
La aplicación del método estadístico ANOVA de un solo factor, permite determinar los mejores atributos que ingresan a la matriz general mediante el análisis de los 18 atributos. Tomando en consideración en el método el mayor valor de R^2 , puesto que los valores cercanos al 100 % indican que existe un correcto ajuste de los datos al modelo, es decir, se determina la variación entre los atributos. Además, en el método se consideran los valores de p próximos a 0 que determinan si los atributos son estadísticamente significativos [12].

Respecto a la matriz de correlación, se descartaron los atributos que contienen coeficientes próximos a -1 o 1, dado que con los mismos existe una relación fuerte entre las variables, ya sea negativa (-1) o positiva (1). En efecto se seleccionaron los atributos con coeficientes próximos a cero, puesto que con estos atributos no existe una correlación fuerte entre las variables [13].

En cuanto al método de Random Forest, permite obtener la estimación de importancia de atributos con uso de los métodos de Curvature test, Standard CART e Interaction test. Posterior a ello, se aplicó el análisis de Pareto para seleccionar los atributos de mayor prioridad, considerando solo el primer 95 % de la distribución acumulada [14].

Los resultados de los métodos estadísticos aplicados: ANOVA, matriz de correlación y Random Forest se observan en la Tabla 2.

La matriz general contiene los 18 atributos correspondientes a las 19 condiciones inducidas a la unidad experimental.



Selección de atributos para entrenamiento de la RNA

Para seleccionar los atributos que serán considerados en la entrada de la red neuronal se realizó un análisis de coincidencia en la Tabla 2 en el cual se seleccionaron los atributos que más se repiten entre los resultados de cada método estadístico aplicado. Los atributos que más se repiten se muestran en la Tabla 3, corroborando la efectividad de cada método utilizado.

4. Conclusiones

El modelo de red neuronal desarrollado posee un error de clasificación de $1,89e-11$ con la función de entrenamiento `trainscg`, lo que permitió la identificación precisa de los diferentes tipos de condiciones mecánicas del MEP, por lo que constituye una alternativa claramente viable para ser integrada en un sistema de diagnóstico, debido a la rapidez computacional que ofrecen las redes neuronales artificiales.

Mediante el desarrollo del análisis de varianza de un solo factor, se obtuvo un valor de p ($p\text{-value}=0,965$) demostrando que la respuesta real de clasificación de fallas mecánicas es equivalente al resultado obtenido mediante la RNA, de manera que con este valor se demuestra que no existe una diferencia estadísticamente significativa.

En este trabajo se muestra que la aplicación de redes neuronales (feed-forward backpropagation) es válida para la detección de condiciones de fallas mecánicas en motores de encendido provocado; además, la técnica de diagnóstico aplicada presenta la ventaja de evitar el desarmado de elementos y piezas del motor con una técnica mínimamente invasiva fiable y de gran precisión. Para determinar los mejores atributos para el entrenamiento de la RNA se aplicó diferentes métodos estadísticos: análisis de varianza (ANOVA), matriz de correlación, Random Forest, de los cuales se agrupó los

resultados en una matriz general que permitió escoger los de mayor coincidencia e importancia para la diferenciación de patrones de fallas mecánicas.

REFERENCIAS

Referencias en la Web:

[1]

<https://brilliant.org/wiki/backpropagation/#:~:text=Backpropagation%2C%20short%20for%20%22backward%20propagation,to%20the%20neural%20net%20work's%20weights.>

[2]

<https://www.toptal.com/machine-learning/un-tutorial-de-aprendizaje-profundo-de-perceptrones-a-redes-profundas>

[3]

<https://www.crehana.com/co/blog/desarrollo-web/que-es-perceptron-algoritmo/>

[4]

Incibe-cert. (2015) Incibe-cert. [Online]. Available: <https://goo.gl/5h7696>

[5]

Mathworks. (2018) Mathworks. [Online]. Available: <https://goo.gl/GVhckj>

[6]

J. Calderón, B. Castillo, and J. Moreno, “Diseño de una red neuronal para la predicción del coeficiente de pérdidas primarias en régimen de flujo turbulento,” *INGENIUS*, vol. 20, pp. 21–27, 2018. [Online]. Available: <https://doi.org/10.17163/ings.n20.2018.02.>